



Méthodes Numériques et Modélisation

Fondements de l'intelligence artificielle et applications aux sciences atmosphériques



CLASSIFICATION

- Associer à chaque donnée un label (étiquette) parmi un ensemble de labels possibles
- Classification binaire
 - Deux classes -> on peut faire un "est-ce X" oui ou non
- Classification multiclasse
 - Plusieurs méthodes
 - Binaire pour chaque classe
 - "vrai" multiclasse -> probabilité générale
- Cas particuliers
 - Classification multilabel
 - Une donnée peut appartenir à plusieurs classes
 - Détection d'objets
 - Classer des éléments d'une image (et pas toute l'image)
 - Segmentation
 - Chaque pixel de l'image sera classé (puis associés)



Classification

Prédire une classe (qualitative, discrète)




This is a cat



This is a rabbit




Tell me,
what is it ?



WHAT IS A

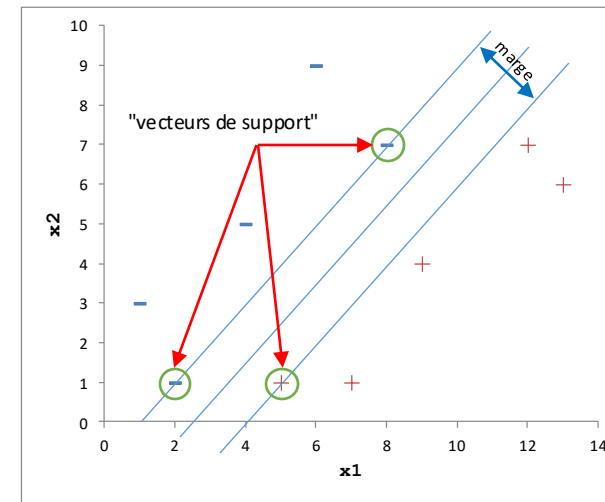


SUPPORT VECTOR MACHINE?



Les SVM


LES SVM

- Les "Support Vector Machines" sont des méthodes proches de l'algèbre linéaire très populaires à la fin des années 90, début 2000
- À la base, le principe est proche de celui de la régression logistique simple, mais associée à une recherche d'une marge de sécurité plus grand
 - Il ne suffit pas de trouver la fonction de séparation, il faut trouver la meilleure fonction
 - doit maximiser la distance entre la frontière de séparation et les points de chaque classe qui lui sont le plus proche
 - D'où le surnom en français "Séparateur à Vastes Marges"



FAIRE APPEL À UNE DIMENSION SUPÉRIEUR

- L'astuce de SVM pour traiter des données qui ne sont pas séparables avec une ligne est de chercher de l'ordre dans une dimension supérieure
 - Ex : on rajoute une troisième colonne Z avec la formule $z = x^2 + y^2$
- Cette petite modification permet à SVM de trouver un hyperplan quand on regarde les données plotées sur les axes X-Z



- Différents types d'opération peuvent être utilisées pour créer ces dimensions supérieures

LES ASTUCES DES SVM (KERNE TRICKS)

- Dans le cas d'un SVM linéaire, le plan de coupe (hyperplan) est déterminé grâce à de l'algèbre linéaire
 - Ex : $f(x) = aX + b$
- un SVM linéaire peut être obtenu à partir du produit intérieur de deux observations
 - Ex : le produit intérieur de deux vecteurs $[2,3]$ et $[5,6]$ est $2*5+3*8=28$
 - Donc on peut utiliser une fonction $f(x) = \text{somme}(a_i*(x,x_i))+b$
 - Le terme "Kernel" définit alors ce produit intérieur : $K(x,x_i) = \text{somme}(x * x_i)$
 - On obtient ainsi un "**Kernel trick**" très populaire lorsqu'on a un grand nombre de features car ce calcul est rapide

AUTRES KERNEL TRICKS

- Kernel Trick Polynomial -> $F(\mathbf{x}, \mathbf{x}_j) = (\mathbf{x} \cdot \mathbf{x}_j + 1)^d$
 - Moins populaire, ici d indique le degré du polynôme
- Gaussian Radial Basis Function (RBF) -> $F(\mathbf{x}, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x} - \mathbf{x}_j\|^2)$
 - L'un des plus populaires, il faut donner une valeur γ entre 0 et 1 (souvent 0.1)
- Sigmoid -> $F(\mathbf{x}, \mathbf{x}_j) = \tanh(\mathbf{a} \cdot \mathbf{x} + c)$
 - C'est la fonction utilisée dans les réseaux de neurones
- Mais aussi Gaussian, Bessel, ANOVA...
 - Le kernel linéaire est préféré pour les problèmes de classification de texte car il fonctionne bien pour les grands ensembles de données
 - Les kernels gaussiens donnent de bons résultats lorsqu'il n'y a pas d'informations supplémentaires concernant les données
 - Le kernel RBF est comme un kernel gaussien qui projette les données à de grandes dimensions et recherche ensuite une séparation linéaire pour celles-ci
 - Les kernels polynomiaux donnent de bons résultats pour les problèmes où toutes les données d'apprentissage sont normalisées

SVM AVEC SCIKIT LEARN

- L'exemple de l'Iris, bien sûr ;)
 - Tout d'abord, les import, la lecture des données et la prépa pour la visualisation


```
1  ## Required Python Packages
2  import pandas as pd
3  import numpy as np
4  import matplotlib.pyplot as plt
5  from sklearn import svm, datasets
6
7  ## Load iris dataset
8  iris = datasets.load_iris()
9
10 ## Create features and target data
11 X = iris.data[:, :2]
12 y = iris.target
13
14 ## Plotting
15 x_min, x_max = X[:, 0].min() - 1, X[:, 0].max() + 1
16 y_min, y_max = X[:, 1].min() - 1, X[:, 1].max() + 1
17 h = (x_max / x_min)/100
18 xx, yy = np.meshgrid(np.arange(x_min, x_max, h), np.arange(y_min, y_max, h))
19 X_plot = np.c_[xx.ravel(), yy.ravel()]
```


SVM AVEC SCIKIT LEARN

■ Un Linear Kernel

```
2  ## Creating the linear kernel
3  svc_classifier = svm.SVC(kernel='linear', C=C).fit(X, y)
4  C = 1.0
5  Z = svc_classifier.predict(X_plot)
6  Z = Z.reshape(xx.shape)
7
8  ## Code of plotting
9  plt.figure(figsize=(15, 5))
10 plt.subplot(121)
11 plt.contourf(xx, yy, Z, alpha=0.3)
12 plt.set_cmap("gist_rainbow")
13 plt.scatter(X[:, 0], X[:, 1], c=y, cmap=plt.cm.Set1)
14 plt.xlabel('Sepal length')
15 plt.ylabel('Sepal width')
16 plt.xlim(xx.min(), xx.max())
17 plt.title('Support Vector Classifier with linear kernel')
```


Text(0.5, 1.0, 'Support Vector Classifier with linear kernel')






Régression Logistique

LINEAR vs. LOGISTIC REGRESSION




@girlie_mac




RÉGRESSION LOGISTIQUE


- La base de la régression logistique est de créer une fonction probabiliste permettant d'identifier les données (surtout pour la classification)



Classification



Regression



EST-CE QU'IL PLEUT DEMAIN ?

x_i = features
for day i



WEATHER

features				outcome
Cloud Cover	Humidity	Temperature	Air Pressure	Did it Rain
0.5	80%	75	1.2	1
0.2	95%	83	1.3	0

$y_i = 1$, yes
 $y_i = 0$, no



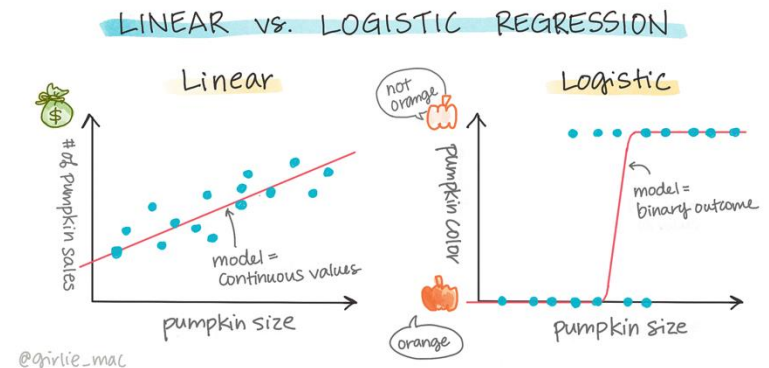
RAIN

$$z_1 = (b_1 \times 0.5) + (b_2 \times 0.8) + (b_3 \times 75) + (b_4 \times 1.2) + b_0 \quad y_1 = 1$$

$$z_2 = (b_1 \times 0.2) + (b_2 \times 0.95) + (b_3 \times 83) + (b_4 \times 1.3) + b_0 \quad y_2 = 0$$

On aurait pu faire un système d'équations linéaires, mais beaucoup de cas "moyens" serait dans l'impasse -> baisse sensibilité/spécificité

On peut encourager les décisions avec une fonction non linéaire




SI ON TRANSFORME TOUT ÇA EN PROBABILITÉS

- La fonction sigmoïde - $\sigma(z_i)$ - est une manière de représenter les prédictions selon un point de vue probabiliste
 - Plus grand et positif est z_i , plus probable sera la valeur y_i
 - Plus petit et négatif est z_i , moins probable sera la valeur y_i

$$z_i = (b_1 \times x_{i1}) + (b_2 \times x_{i2}) + \dots + (b_M \times x_{iM}) + b_0$$


Sigmoid Function $p(y_i = 1 | x_i) = \sigma(z_i)$



EXAMPLE

$$z_i = (b_1 \times 0.5) + (b_2 \times 0.8) + (b_3 \times 75) + (b_4 \times 1.2) + b_0$$

Sigmoid Function $p(y_i = 1|x_i) = \sigma(z_i)$




features

Cloud Cover	Humidity	Temperature	Air Pressure
0.5	80%	75	1.2

- Les paramètres b indiquent combien les variables sont importantes pour la prédiction


ReLU (RECTIFIED LINEAR UNIT)

- Devenue très populaire, ReLU remplace sigmoid
 - introduit de la non-linéarité dans le modèle
 - convergence plus rapide qu'avec sigmoïde
 - le calcul de ReLU est simple à effectuer et ne nécessite pas d'exponentielles coûteuses




COMMENT ÇA MARCHE DANS LA PRATIQUE ?

- Exemple : le dataset MNIST
 - Ensemble de chiffres écrits à la main
- Objectif : identifier le chiffre 1



MISE EN ROUTE

- Les chiffres sont des images, chaque pixel a une valeur numérique




MNIST Dataset of Handwritten Digits (Images)

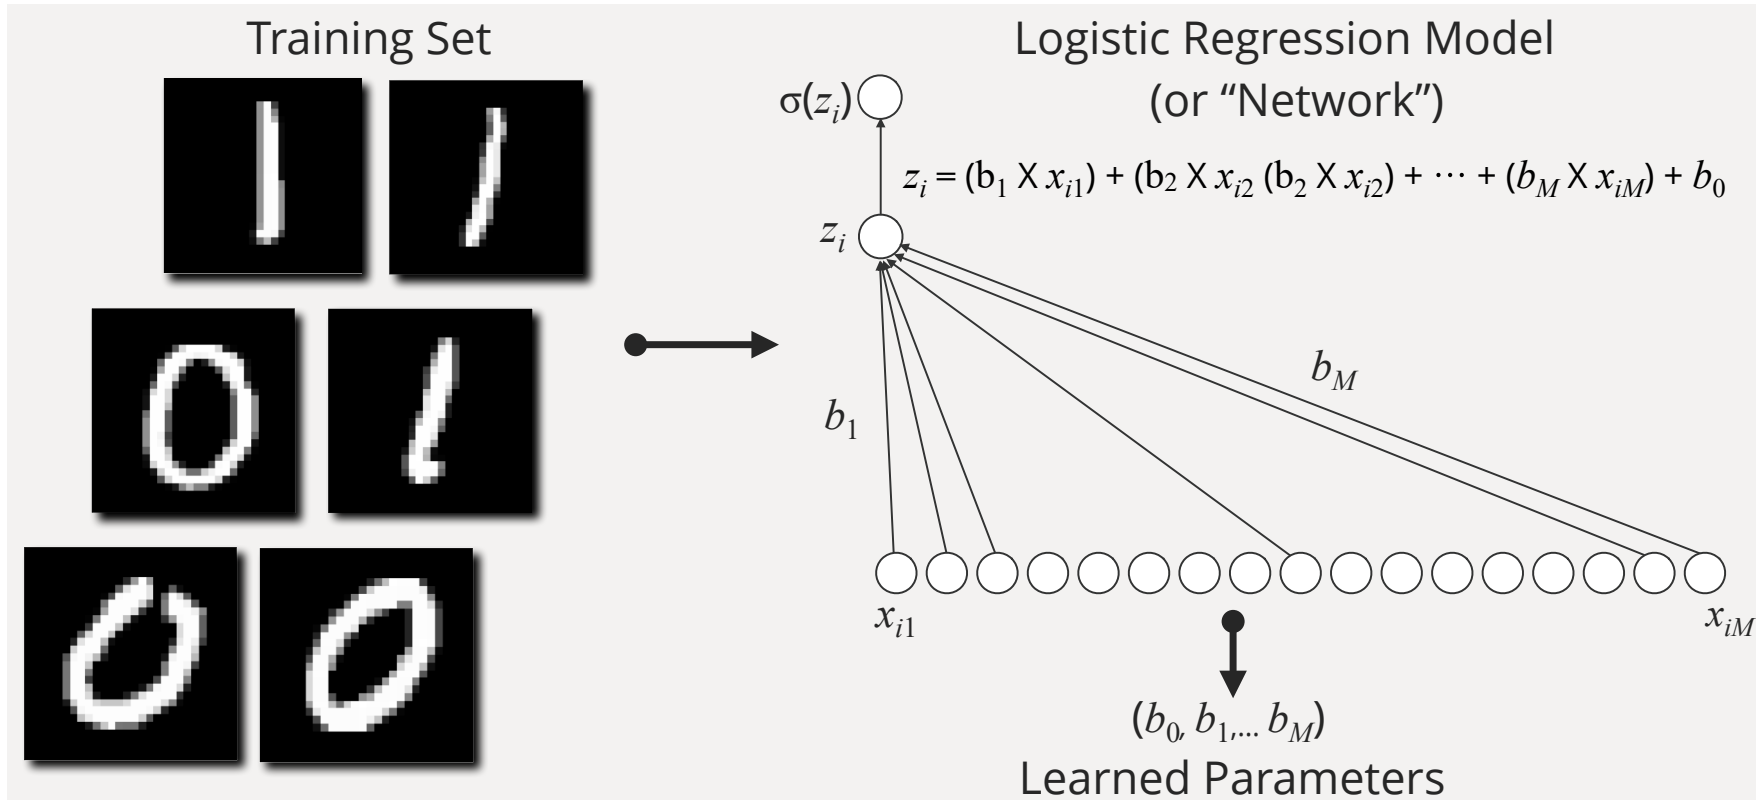
Yann LeCun (Courant Institute, NYU) and Corinna Cortes (Google Labs, New York) CC-by-SA 3.0

<http://yann.lecun.com/exdb/mnist/>

LE CAS SIMPLE : SORTIE BINAIRE

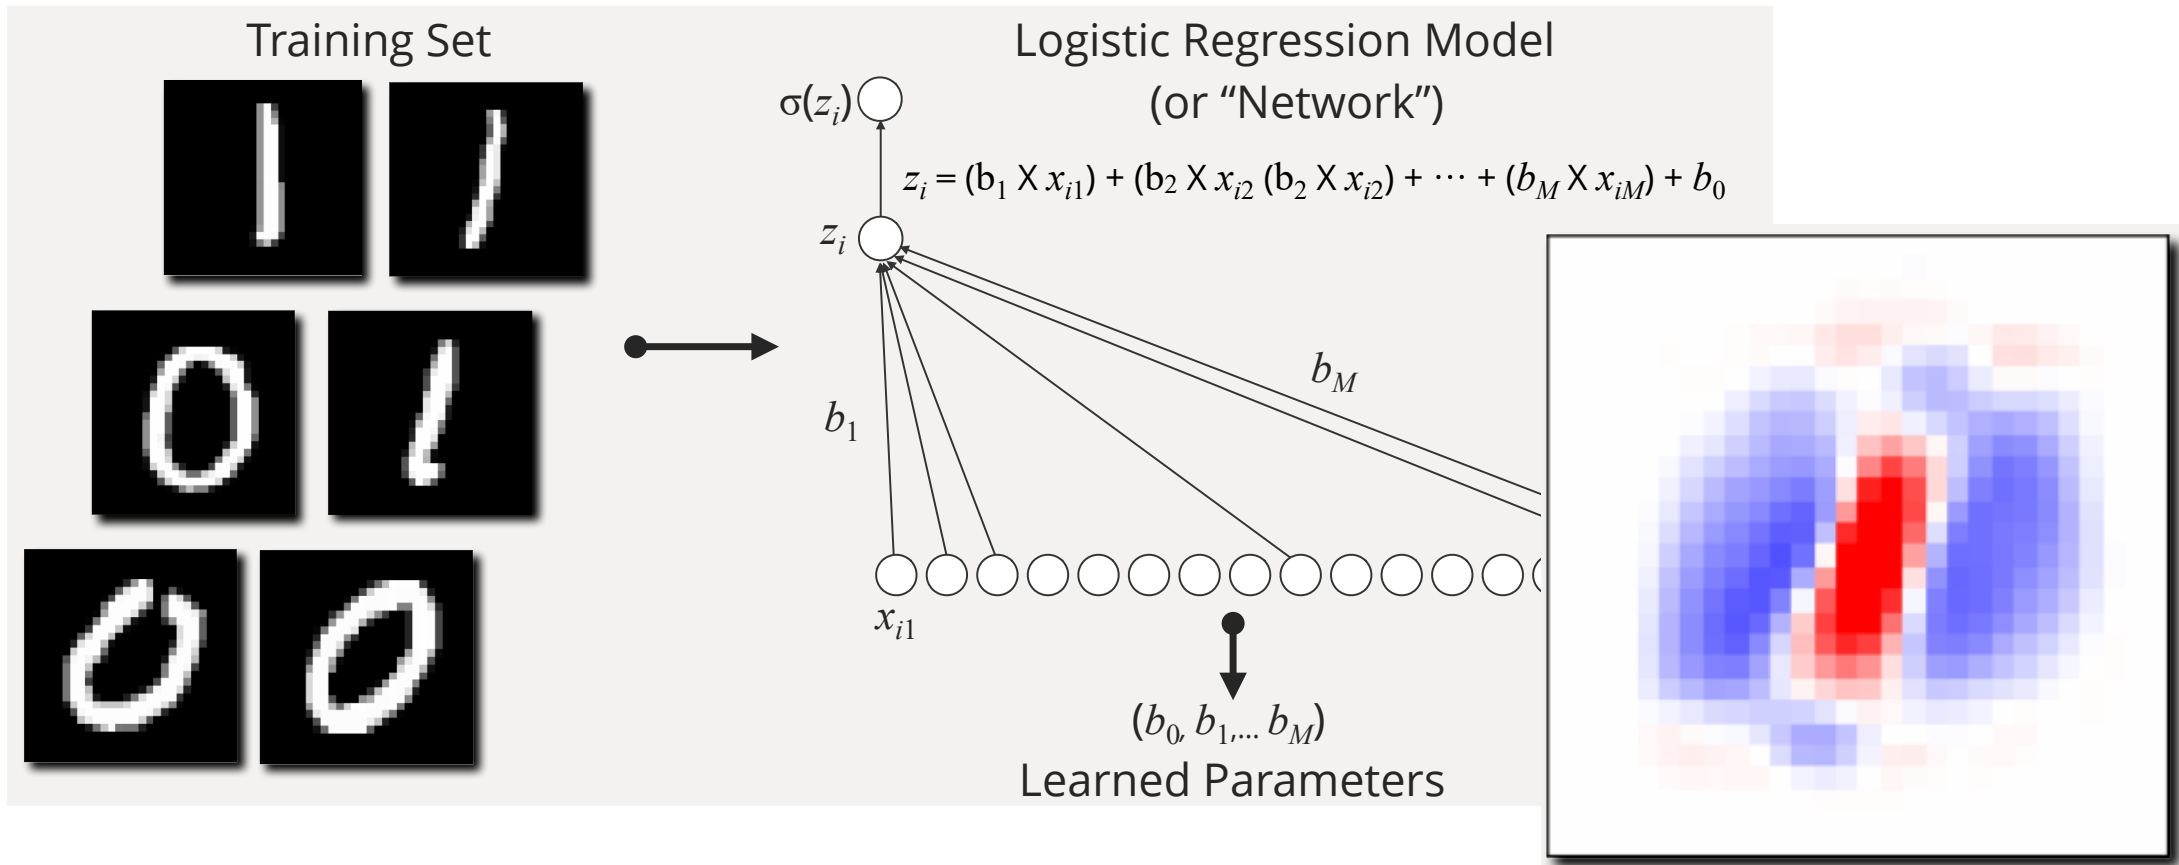


APPRENTISSAGE DU MNIST



Chaque position de la matrice est étiquetée avec une valeur négative (0), positive (1) ou rien. Plus on a des 0 ou 1, plus la "case" est fortement marquée (poids de b)

APPRENTISSAGE DU MNIST





Chaque position de la matrice est étiquetée avec une valeur négative (0), positive (1) ou rien. Plus on a des 0 ou 1, plus la "case" est fortement marquée (poids de b)

FONCTION LOGISTIQUE

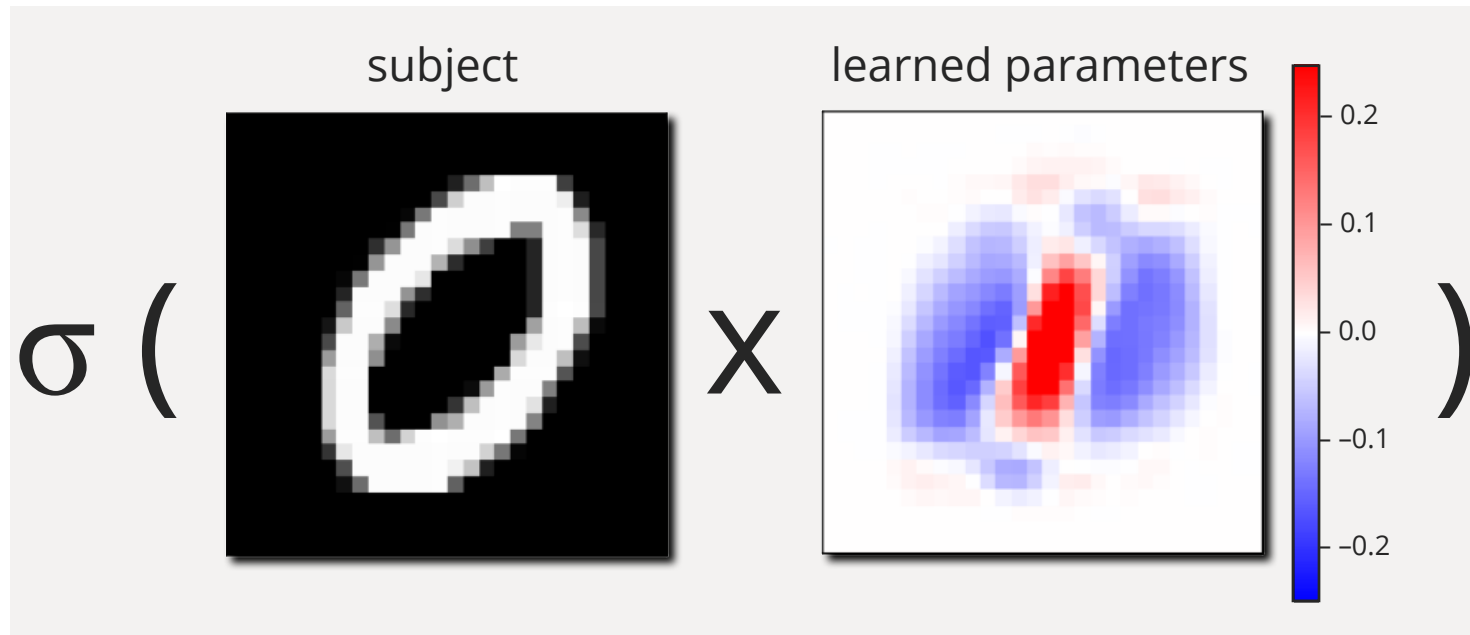
$$z_i = (b_1 \times x_{i1}) + (b_2 \times x_{i2}) + \dots + (b_M \times x_{iM}) + b_0$$

Sigmoid Function $p(y_i = 1|x_i) = \sigma(z_i)$



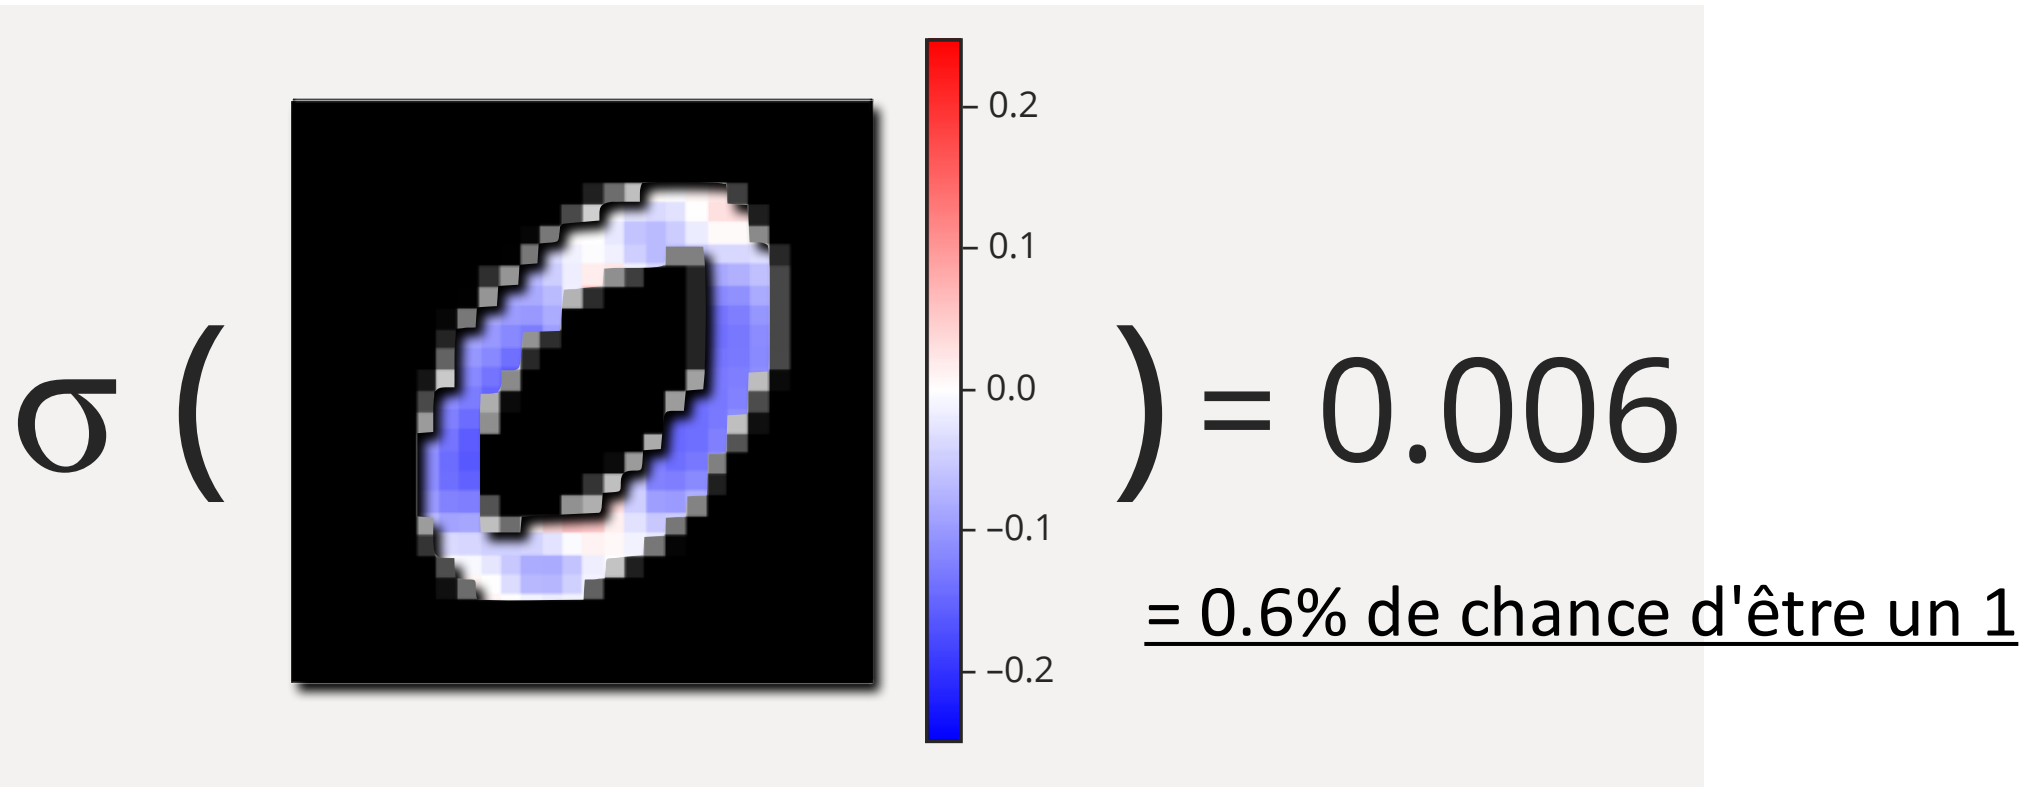
QUELLE EST LA PROBABILITÉ D'ÊTRE UN ZÉRO ?

- Pour un chiffre donné, on compare sa matrice avec la matrice entraînée :




PROBABILITÉ D'UN ZÉRO

- La "superposition" donne une note pour les parties communes



PROBABILITÉ D'UN UN

- La "superposition" donne une note pour les parties communes



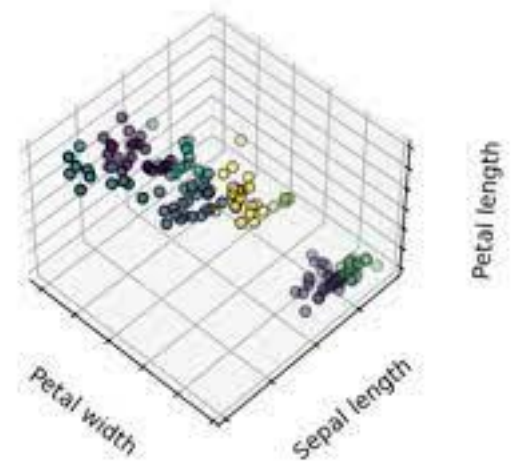
REGRESSION LOGISTIQUE DANS SKLEARN


- L'exemple de l'Iris

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LogisticRegression
from sklearn import datasets

# import some data to play with
iris = datasets.load_iris()
X = iris.data[:, :2] # we only take the first two features.
Y = iris.target


# Create an instance of Logistic Regression Classifier and fit the data.
logreg = LogisticRegression(C=1e5)
logreg.fit(X, Y)
```






LIMITATIONS DE LA RÉGRESSION LOGISTIQUE

- Les classifieurs linéaires sont limités dans leurs possibilités
- Souvent on a des données non-linéaires




112 Atmosphere / Climat



EN RÉSUMÉ...

- On a vu des des algorithmes encore plus avancés pour la classification
- Il n'y a pas un algorithme meilleur que l'autre
 - Ça dépend des jeux de données
 - Ça dépend des métriques qu'on veut favoriser
- Dans le prochain cours nous allons regarder plus en détail
 - La régression linéaire
 - Les réseaux de neurones
 - Les séries temporelles



QUELQUES EXERCICES

- Ouvrir lien suivant et suivre les liens des exercices

- <https://tinyurl.com/yrpunv8>

- ou

- [https://github.com/lsteffene1/M2Atmo et Climat/blob/main/README.md](https://github.com/lsteffene1/M2Atmo_et_Climat/blob/main/README.md)

- Cela vous amènera dans un environnement Google Colab