


Méthodes Numériques et Modélisation

Fondements de l'intelligence artificielle et applications aux sciences atmosphériques




Deep Learning

Pourquoi ça change la météorologie ?



EXEMPLES AVEC DE LA CLASSIFICATION


- Détection d'évènements extrêmes
 - Ouragans, cyclones, typhons
 - Vagues de chaleur
- Segmentation des nuages selon leur type



<https://amt.copernicus.org/articles/13/5459/2020/>

- Aussi en terre
<http://ieee-dataport.org/open-access/benchmark-dataset-automatic-damaged-building-detection-post-hurricane-remotely-sensed>

Master M2
RNET





<https://gmd.copernicus.org/articles/15/7051/2022/>



ET LES SÉRIES TEMPORELLES ?



- Plusieurs études utilisent le LSTM ou des modèles similaires pour prédire les polluants dans les environnements urbains
 - Exemple : prévisions sur 1 heure pour les PM2,5 en Malaisie



<https://www.nature.com/articles/s41598-022-21769-1>

ASSEZ UTILE AUSSI POUR DES PARAMÈTRES CLIMAT

- Comparaison entre ERA5 et un modèle IA pour les cycles quotidiens de température
 - Température à 2 m
 - Prévisions à 2 jours
- 2 sites « connexes »
 - Amazonie et océan Atlantique
 - Australie et océan Indien



PRÉDICTION DE TRAJECTOIRES

- Les séries temporelles par IA sont "multiparamétriques"
 - Permet d'associer plusieurs variables, comme par exemple les coordonnées
- Exercice simple :
 - Utiliser un GRU pour estimer la trajectoire d'un "insect"





Fig. 14 Visualization of prediction error for Typhoon Talim


CAPTEURS AU SOL

- Une série chronologique pour « un point » n'est pas toujours suffisante
 - Dépendance vis-à-vis des événements voisins
- Que faire ? Relier les points ? Presque
- MLAir
 - Projet allemand combinant des séries chronologiques LSTM et des échanges 2D avec les stations voisines
 - Les valeurs des voisins proches deviennent des "features"
- Intéressant pour les réseaux de capteurs au sol




DES MODÈLES UN PEU PLUS COMPLEXES

- Lorsque les données forment des matrices, il est possible d'utiliser des techniques d'IA pour les images
 - Et pas seulement pour la classification/segmentation
- Modèle UNet (encodeur-décodeur avec connexions de saut)
 - Initialement créé pour segmenter les images médicales
 - L'entraînement consiste à montrer les images originales et les images « cibles »




- Comment détourner son usage ?
 - Image RGB = 3 canaux pour les couleurs
 - Même "pas temporel"
 - Mais on peut aussi rajouter des canaux séquentiels



UNET POUR LE FORECAST RADAR (NOWCAST)

- Le modèle UNET peut également accepter plusieurs images d'entrée
- Il génère une seule sortie, mais il est possible de « faire glisser » la fenêtre pour obtenir davantage d'itérations
 - Aucune connaissance en géophysique n'est requise
- Également utilisé dans les modèles expérimentaux de l'ECWMF




GÉNÉRATION DE LA PROCHAINE TRAME

- Plusieurs travaux s'intéressent à la « prédiction de l'image suivante »

- Estimation de l'action suivante d'un objet


- Trajectoire d'une voiture ou d'un vélo
- Compléter une séquence de données



- L'image suivante nécessite un apprentissage spatio-temporel important

- Ne pas déformer l'objet (états « connus »)
- Maintenir une trajectoire cohérente
- Estimer les interactions entre les objets


- Ce type d'utilisation a été rapidement adapté aux prévisions météorologiques, en particulier dans les nowcast



PredRNN++: Towards a Resolution of the Deep-in-Time Dilemma in Spatiotemporal Predictive Learning. Wang, Yunbo and Gao, zhifeng and Long, Mingsheng and Wang, Jianmin and Yu, Philip S., ICML, 2018



ADVECTION SCALAIRE DE L'OZONE

- Focus sur les événements secondaires liés à l'ozone (OSE) au-dessus de l'Amérique du Sud
 - Utilisation de PredRNN++, un modèle de « prévision de la trame suivante »
- Résultats prometteurs pour les 3 à 5 jours à venir
 - Similitudes en termes de circulation et d'échelle
 - Possibilité d'extraire les valeurs TCO pour les comparer avec les équipements au sol (Brewer/Dobson)
- Problèmes :
 - le modèle ne « voit » pas les événements "en dehors de la fenêtre"




ADAPTER LES DONNÉES

- Projection polaire
 - Préservation des masses et de la quantité de mouvement sur plusieurs jours
 - Intégrité structurelle
-
- L'entraînement du modèle est coûteux
 - Plus de 24 heures sur un GPU V100
 - Mais l'inférence est immédiate
 - Même sur un petit ordinateur portable





MODÈLES DE DIFFUSION

- Le succès des modèles de diffusion probabilistes (Dall.E, Midjourney) donne des idées
- Principe : créer des images à partir d'un « espace latent » apparemment aléatoire
 - L'entraînement consiste à ajouter du bruit aux images
- Pour la génération, l'outil « projette » la recherche sur l'espace latent, en supprimant le bruit




MODÈLES DE DIFFUSION

- Prédiction de la couverture nuageuse



https://wandb.ai/capecape/ddpm_clouds/reports/Diffusion-on-the-Clouds-Short-term-solar-energy-forecasting-with-Diffusion-Models--VmIldzozNDMxNTg5



- Nous avons essayé ce modèle avec l'ozone (3 trames d'entrée, génération récursive)
 - Faible préservation du moment, tendance à redevenir du « bruit »



EST-CE QUE LES LLM PEUVENT NOUS AIDER ?


- Mécanisme d'attention / Transformers
 - La base des modèles linguistiques (ChatGPT) a également révolutionné la vision par ordinateur
 - Difficile à entraîner, mais peut donner un sens « sémantique » aux données

The restaurant refused to serve me a ham sandwich, because it only cooks vegetarian food. In the end, they just gave me two slices of bread. Their ambiance was just as good as the food and service.



RÉSULTATS RÉCENTS SUR LES AÉROSOLS

- Projet sur l'impact des aérosols des feux de forêt sur les anomalies des nuages et des précipitations
- Exemple : prévision des 4 prochains jours (par tranches de 12 heures) à partir des 5 jours précédents
 - **Black Carbon Optical Depth at 550nm**




- Bonus : **entraînement rapide** (moins d'une heure), juste gourmand en mémoire GPU

MAIS AUSSI AVEC DES CYCLONES


- Exemple rapide avec 4 vidéos de cyclones
 - Dingani (janvier 2023)
 - Belal (janvier 2024)
 - Candice (janvier 2024)
 - Djoungou (février 2024)
- Données réduites pour s'exécuter sur Colab
- <https://t.ly/EUZ8e>



input






input



ET LES MODÈLES IA "EARTH-SYSTEM MODELING"

- Les grands centres tentent de créer des modèles de la planète entière
 - Chine (PanguWeather), ECWMF, NVIDIA (FourCastNet), etc.
- Une grille large permet de « lisser » certaines erreurs
- Mais tout dépend de la propagation de l'erreur...





POTENTIELS ET LIMITES


- Une étude ECWMF de 2022 a comparé un modèle IA (déjà avec ensemble) et le modèle ECWMF actuel
 - À court terme, le modèle ECWMF est encore plus précis (mais les deux battent la climatologie)
 - Très peu de différence à long terme
- Le coût d'exécution des modèles IA permet d'exécuter plus de variations

Comparison of Key Attributes of Our DLWP Ensemble and Those of the State-of-the-Art ECMWF Ensemble for Extended-Range Forecasting

	DLWP	ECMWF
Atmospheric fields	6 spherical shells	819 spherical shells
Horizontal resolution	150 km	18 km (36 km after day 15)
Atmospheric physics	3 prescribed inputs	Many physical parameterizations
Coupled models	None	Ocean, wave, and sea ice models
Initial condition perturbations	10 (ERA5 uncertainty)	50 (SVD/4DVAR)
Model perturbations	Perturbed CNN weights	Stochastic physics
Ensemble members	320 (+control)	50 (+control)





EXEMPLE : LE NOUVEAU EARTH-2 DE NVIDIA




PHYSICS-INFORMED NEURAL NETWORKS

- Les modèles IA classiques extraient des informations à partir des données
 - Aucune connaissance de la physique de l'atmosphère
 - Tentative et erreur pour atteindre une métrique (RMSE, par exemple)
- Les réseaux PINN sont un travail récent qui tente d'introduire des systèmes d'équations pour « guider » l'entraînement



LIMITS OF DEEP LEARNING



- Traditional DL is entirely based on data
 - Lots of data at the input
 - Try to minimize error at the output (using RMSE, for example)



- Sometimes, only data is not enough

LIMITS OF DEEP LEARNING

- Traditional DL is entirely based on data
 - Lots of data at the input
 - Try to minimize error at the output (using RMSE, for example)



- Sometimes, only data is not enough
 - How to inform NN of relations between physical quantities?

LIMITS OF DEEP LEARNING

- Traditional DL is entirely based on data
 - Lots of data at the input
 - Try to minimize error at the output (using RMSE, for example)


#Loss

```
mse = tf.keras.losses.MeanSquaredError()
```

```
def loss_dp(y_true, y_pred):  
    return mse(y_true, y_pred**2)
```


```
optimizer_dp = tf.keras.optimizers.Adam(learning_rate=0.001)
```

```
nn_dp.compile(optimizer=optimizer_dp, loss=loss_dp)
```




PHYSICS INFORMED NEURAL NETWORKS (PINNs)

- Physics-informed neural networks is one way to "guide" the deep learning
 - Most problems can be expressed as Partial Differential Equations (PDE)
- PDEs can be used to set tests to drive the model
 - "field" and "boundaries" equations
- Loss = Loss_{nn} + Loss_{pde}**
- Indeed, most PINN libraries are PDE solvers that try to use deep learning under the hood
 - Not as good as other "pure" PDE solvers
 - But excellent for specific problems




HOW TO THINK ABOUT "PDE+BOUNDARY LOSS"

- Consider a scenario for the 2D "heat equation"
- We have a starting scenario like this :



HOW TO THINK ABOUT "PDE+BOUNDARY LOSS"

- Consider a scenario for the 2D "heat equation"
- We have a starting scenario like this :




- At a given instant t , we can measure the temperature at a given point
- However, we don't want (can't) obtain data for each point at each time step
 - But we know how temperature spreads...

HOW TO THINK ABOUT "PDE+BOUNDARY LOSS"

- This time, we measure only a limited number of data points
 - As in any neural net, we want to reduce the loss (eg: MSE)


MSE loss

$$\frac{1}{n} \sum_{i=1}^n (\hat{T}(x_i, y_i, t_i) - T(x_i, y_i, t_i))^2$$



HOW TO THINK ABOUT "PDE+BOUNDARY LOSS"

- This time, we measure only a limited number of data points
 - As in any neural net, we want to reduce the loss (eg: MSE)
 - Missing points can be derived with PDE



MSE loss


$$\frac{1}{n} \sum_{i=1}^n (\hat{T}(\mathbf{x}_i, \mathbf{y}_i, t_i) - T(\mathbf{x}_i, \mathbf{y}_i, t_i))^2$$

Physical loss

$$\frac{1}{N} \sum_{j=1}^N \left(\frac{\partial \hat{T}}{\partial t}(\mathbf{x}_j, \mathbf{y}_j, t_j) - D \Delta \hat{T}(\mathbf{x}_j, \mathbf{y}_j, t_j) \right)^2$$

HOW TO THINK ABOUT "PDE+BOUNDARY LOSS"

- This time, we measure only a limited number of data points
 - As in any neural net, we want to reduce the loss (eg: MSE)
 - Missing points can be derived with PDE (*collocation points*)
 - And we define also the "boundary" rules



MSE loss

$$\frac{1}{n} \sum_{i=1}^n (\hat{T}(\mathbf{x}_i, y_i, t_i) - T(\mathbf{x}_i, y_i, t_i))^2$$

Physical loss


$$\frac{1}{N} \sum_{j=1}^N \left(\frac{\partial \hat{T}}{\partial t}(\mathbf{x}_j, y_j, t_j) - D \Delta \hat{T}(\mathbf{x}_j, y_j, t_j) \right)^2$$

Boundary loss

$$\frac{1}{M} \sum_{k=1}^M (\hat{T}(\mathbf{x}_k, y_k, t_k) - T(\mathbf{x}_k, y_k, t_k))^2$$

$$\frac{1}{P} \sum_{l=1}^P (\nabla \hat{T}(\mathbf{x}_l, y_l, t_l) \cdot \vec{n} - \phi(\mathbf{x}_l, y_l, t_l))^2$$

SUMMING UP...



MSE loss


$$\frac{1}{n} \sum_{i=1}^n (\hat{T}(x_i, y_i, t_i) - T(x_i, y_i, t_i))^2$$

Physical loss

$$\frac{1}{N} \sum_{j=1}^N \left(\frac{\partial \hat{T}}{\partial t}(x_j, y_j, t_j) - D \Delta \hat{T}(x_j, y_j, t_j) \right)^2$$

Boundary loss

$$\frac{1}{M} \sum_{k=1}^M (\hat{T}(x_k, y_k, t_k) - T(x_k, y_k, t_k))^2$$
$$\frac{1}{P} \sum_{l=1}^P (\nabla \hat{T}(x_l, y_l, t_l) \cdot \vec{n} - \phi(x_l, y_l, t_l))^2$$



$\mathcal{L}$

PHYSICS INFORMED NEURAL NETWORKS (PINNs)


- A problem with NNs and the promise of PINNs

Physics Only

$$\frac{\delta^2 u}{\delta x^2}(x) = 1 \quad u(0) = u(1) = 0$$

$$L_{physics} = L_{residual} + L_{BC}$$

$$L_{total} = L_{physics}$$




RINEI

Data + Physics

$$\frac{\delta^2 u}{\delta x^2}(x) = 1$$

$$L_{physics} = \sum_{x_j \in domain} \left(\frac{\delta^2 u_{net}}{\delta x^2}(x_i) - f(x_i) \right)^2$$


$$L_{total} = L_{data} + L_{physics}$$



Data only

$$L_{data} = \sum_{x_i \in data} (u_{net}(x_i) - u_{true}(x_i))^2$$

$$L_{total} = L_{data}$$



BONUS : INVERSED PROBLEM


- PINNs are a way to "drive" the training using PDEs and boundary conditions
- If we known the basic model that represents a system but we are not sure about the parameters values, PINNs can also help finding them

L'IA VA REMPLACER LES MODÈLES TRADITIONNELS ?

- Les modèles IA se reposent sur l'assimilation des données pour définir l'état initial de l'atmosphère
 - L'assimilation n'est pas toujours précise et est souvent revue
- La résolution spatiale des modèles IA est fréquemment limitée à $0,25^\circ$ (~30 km), ce qui empêche de représenter des petits phénomènes comme les orages
 - Les données source (ERA5) sont dans cette résolution
- En comparaison, les modèles traditionnels de prévision numérique (NWP) peuvent atteindre une résolution de 3 km et détecter mieux les petits systèmes
- Les modèles IA prédisent un nombre limité de variables météorologiques
 - Ne produisent pas de prévisions sur le type des précipitations, les rafales de vent et les nuages
- Leur capacité à anticiper des événements extrêmes (ouragans, fortes pluies, vagues de chaleur ou froid) reste incertaine



DL COMME OUTIL AUXILIAIRE DE TRAVAIL

- L'intelligence artificielle n'est pas une concurrente, mais un outil
 - Qui utilise encore des **règles à calcul** ?
- Comme l'ENIAC dans les années 50, l'IA est venue faciliter les tâches fastidieuses
 - Calculer des centaines d'équations dérivées partielles
 - Traiter en parallèle des données provenant de plusieurs sources/multiparamétriques
 - Identifier des modèles, des corrélations...
- Quelques exemples de ce que l'IA peut nous aider à avancer




COMPLÉMENTER LES MODÈLES ENSEMBLE

- Le coût d'exécution d'un modèle IA est faible
 - Multiplication des modèles = meilleure couverture
- Possibilité d'associer un modèle CNN pour choisir les meilleures sorties de l'ensemble
 - Les conditions initiales peuvent servir à guider la sélection de la sortie




PARAMÉTRISATION AUTOMATIQUE DES RÉANALYSES

- Les données satellitaires ne correspondent pas exactement à ce que nous essayons de mesurer
 - Exemple : température du sol
 - Le satellite mesure le rayonnement infrarouge réfléchi par le sol
 - Un modèle convertit ce taux d'infrarouge en température
- Les modèles climatiques doivent également être corrigés pour se rapprocher de la réalité des observations
 - Cette réanalyse des données est régulièrement mise à jour
 - ERA-Interim
 - ERA5
 - ERA5-land
- Les modèles d'IA peuvent aider à automatiser cette correction, en assimilant les données d'observations et en produisant de nouveaux paramètres pour les modèles



RECHERCHE DE CAUSALITÉ

- Une corrélation ne suffit pas toujours pour établir un lien de causalité
- Latent Convergence Cross-Mapping (<https://github.com/edebrouwer/latentCCM>)



EN RÉSUMÉ

- Les modèles numériques du climat reposent sur des équations physiques et l'assimilation de données d'observation
- L'intelligence artificielle (IA) s'impose comme un outil complémentaire, notamment pour la classification d'événements extrêmes, les séries temporelles et la prédiction de trajectoires
- Les modèles IA apportent des solutions rapides pour l'analyse et la correction automatique des paramètres, mais leur capacité à représenter l'ensemble des phénomènes et variables reste limitée
- Les réseaux de neurones informés par la physique (PINN) ouvrent de nouvelles pistes pour intégrer les contraintes physiques dans l'apprentissage
- Le coût d'exécution des modèles IA faible permet des ensembles plus nombreux et variés
- Pour aller plus loin, explorez les travaux récents sur les modèles IA en météorologie et climat, testez différentes architectures (voir Springer, Nature, ECMWF, Copernicus, GitHub)